HACKATHON ANIA · BOXLANG AI · CHALLENGE 06

Data Miner

Un equipo de agentes de IA para la empresa mediana que empieza a tener datos

Comprender el negocio, evaluarlo y anticiparse, preguntando en lenguaje natural y recibiendo respuestas que se pueden comprobar.

Mario · Octubre de 2026

EN UNA FRASE

Data Miner es un **equipo de agentes de IA** (un coordinador y tres especialistas) construido en BoxLang. Recibe una pregunta de negocio en lenguaje natural y trabaja con los datos tal como llegan: un Excel, un CSV, un JSON, Google Drive o la base de datos de la empresa. Antes de que la IA vea nada, **anonimiza los datos personales** (DUI, NIT, nombres, teléfonos, correos). Los entiende sin conocerlos de antemano, **revisa su calidad** y los analiza con SQL, estadística y machine learning. Al final entrega un informe en el que **cada hecho viene con la consulta que lo demuestra**.

Para quién	Qué resuelve	Qué entrega
Empresas medianas con datos en su ERP, su punto de venta, su CRM u hojas de cálculo, pero sin un equipo de datos.	Tener datos dispersos y desordenados y no saber qué dicen. Decidir por intuición porque analizar cuesta tiempo y personal especializado.	Respuestas verificadas, diagnóstico de calidad, gráficas, modelos predictivos y un informe HTML que se comparte o se imprime.

1. La necesidad: empresas que ya tienen datos, pero no respuestas

Una empresa mediana suele llegar a los datos de forma accidental. Instala un sistema de facturación, un punto de venta o un CRM para operar, y al cabo de unos años descubre que tiene miles de registros de ventas, clientes, inventario, créditos o cobranza. Los datos existen; lo que falta es convertirlos en decisiones.

Las dificultades que se repiten son estas:

- **No hay quién analice.** Un científico o analista de datos dedicado es una contratación cara y difícil de justificar mientras no se sabe cuánto valor hay en los datos. Muchas veces el análisis recae en alguien de finanzas o de sistemas que ya tiene otro trabajo.
- **Los datos están dispersos y desordenados.** Parte vive en la base del sistema y parte en Excel con títulos, varias hojas y fórmulas, en CSV exportados con punto y coma o en archivos que nadie documentó. La misma zona aparece escrita como «Norte», «norte » y «NORTE».
- **Nadie sabe si los datos son confiables.** Duplicados, campos vacíos o IDs repetidos pasan desapercibidos hasta que una cifra no cuadra en una reunión.
- **Las herramientas de BI piden saber qué preguntar.** Un tablero muestra lo que alguien decidió medir. No explica por qué cayeron las ventas, qué variables se relacionan con la mora, ni qué cliente es probable que deje de pagar.
- **Desconfianza en las respuestas.** Un asistente de IA que responde sin mostrar de dónde saca las cifras no sirve para una junta directiva.
- **Miedo a tocar la base de producción.** Dar acceso a una herramienta externa a la base que mueve la operación diaria es un riesgo que la gerencia no quiere asumir.

> **La pregunta de fondo de estas empresas no es técnica.** Es: ¿qué está pasando en mi negocio, qué lo explica, y qué va a pasar si sigo igual? Y antes de eso: ¿mis datos sirven para responderlo? Data Miner está diseñado para responder ambas cosas con los datos que ya tienen.

Nota: este documento no cita cifras de mercado. Las afirmaciones de esta sección describen situaciones habituales en empresas medianas, no estadísticas medidas.

2. La idea: un equipo multiagente, no un chatbot

En lugar de un único asistente que intenta hacerlo todo, Data Miner reparte el trabajo entre especialistas, igual que lo haría un departamento de datos. Un **coordinador** recibe la misión, decide a quién delegar y en qué orden, y arma la respuesta final. Ningún agente conoce los datos de antemano: primero los consiguen, luego revisan su calidad y después los consultan.

Es multiagente de verdad: BoxLang AI trae los subagentes como parte del lenguaje (aiAgent(subAgents: [...])). Cada subagente tiene sus propias instrucciones, herramientas y modelo, y el coordinador los ve como herramientas (delegate_to_datos, delegate_to_analista...). Cada agente puede usar incluso un proveedor de IA distinto.

Agente	Qué hace	Para qué le sirve a la empresa
Coordinador	Interpreta la pregunta, decide a quién delegar y redacta la respuesta. Tiene memoria de la conversación.	Se le habla como a un jefe de análisis: «¿por qué bajó el margen este trimestre?»
Datos	Consigue los datos (archivo subido, Google Drive / Sheets, una URL o Kaggle), perfila las tablas, califica su calidad de 0 a 100, limpia una copia, propone el esquema SQL, detecta fuga de datos y aconseja cómo recolectar mejor.	Saber qué datos tiene, si son confiables y qué cambiar en la captura para que sirvan más.
Analista	Consulta con SQL los datos cargados y la base de la empresa vía MCP (solo lectura). Calcula descriptiva, correlación Pearson y Spearman, covarianza y métricas financieras, y crea gráficas.	Ventas por zona, mora por segmento, qué variables se mueven juntas, rentabilidad y riesgo de una serie.
Científico ML	Regresión lineal, ridge, lasso y polinomial; logística, árbol y Random Forest (Tribuo). Compara contra una línea base y revisa la fuga de datos antes de entrenar.	Predecir ventas o montos, estimar qué clientes caerán en impago y qué factores pesan más.

¿Por qué solo tres especialistas? Cada agente conversa varias veces con el modelo de IA, y los planes gratuitos limitan las llamadas por minuto y por día. Agrupar el trabajo en tres agentes da el mismo resultado con menos llamadas: la misión completa de prueba pasa de 30 a 19. Si hay cuota de sobra, un modo «completo» reparte las mismas herramientas entre siete especialistas.

Al final, un paso de **verificación** vuelve a ejecutar la consulta SQL de cada hecho que el equipo afirma. El resultado se separa en dos bloques:

- ✓ **Hechos verificados**: afirmaciones con su SQL, que se comprobaron contra los datos. Si una no se sostiene, aparece marcada con ✗.
- **Interpretaciones**: hipótesis y recomendaciones del equipo, presentadas como tales.

Todo termina en un **informe HTML** con las gráficas, que abre sin internet y se puede imprimir a PDF desde el navegador. La interfaz muestra además la traza de cada acción del equipo.

3. Los datos como llegan: cualquier formato, con diagnóstico de calidad

El usuario arrastra un archivo a la página, o el agente de Datos lo descarga. Data Miner lo convierte en tablas sin pedir que nadie lo prepare antes:

Formato	Qué hace con él
Excel (.xlsx, .xls)	Una tabla por hoja. Salta títulos y filas vacías para encontrar los encabezados, calcula las fórmulas y pasa las fechas a aaaa-mm-dd.
CSV / TSV / TXT	Detecta el separador (coma, punto y coma, tabulador o barra), la coma decimal (1.250,50) y el BOM que agrega Excel.
JSON	Lee una lista de registros, aunque venga dentro de otro objeto, y aplana un nivel de anidación.
ZIP y enlaces	Abre todos los archivos de un ZIP. En un enlace de Drive sin extensión reconoce el tipo por el contenido.

Apenas se sube un archivo, el agente de **Datos** muestra un diagnóstico sin necesidad de IA: un puntaje de calidad y cada problema con su severidad y una recomendación concreta.

Revisa	Ejemplo de lo que encuentra	Recomendación que da
Completitud y unicidad	«Vendedor vacío en 29 de 62 filas»; «2 filas duplicadas»; «ID de cliente repetido»	Hacer el campo obligatorio en la captura; que el sistema genere el ID
Consistencia	«Norte», «norte » y «NORTE» como zonas distintas; fechas dd/mm/aaaa mezcladas con aaaa-mm-dd	Listas desplegables en lugar de texto libre; fechas ISO 8601
Validez	Montos guardados como texto («$1,200»); valores atípicos; stock negativo	Guardar el número sin formato; validar rangos al capturar
Privacidad	Columnas con correo, teléfono o nombre de clientes	Consentimiento, acceso mínimo y anonimizar antes de compartir
Fuga de datos (ML)	«dias_mora_max» casi predice «impago» por sí sola, pero se conoce después	Quitarla del modelo; guardar una «foto» de las variables al momento de decidir

Además puede **limpiar** una copia de la tabla (la original no se toca), proponer el **CREATE TABLE** para llevarla a una base de datos y dar **consejos de recolección** adaptados a lo que encontró: validar en el punto de captura, mantener un diccionario de datos, separar datos crudos de datos limpios y preferir una base de datos a un Excel enviado por correo.

> Para una empresa mediana este diagnóstico suele ser tan valioso como el análisis: le dice **qué cambiar en su forma de capturar datos** para que el análisis del próximo año sea mejor.

4. Cómo ayuda a comprender y evaluar el negocio

Comprender

El primer valor es saber qué hay y en qué estado está. El agente de Datos y el Analista responden preguntas como «¿qué datos tengo y son confiables?», «¿cuál es el ticket promedio y cuánto varía?» o «¿qué tres hallazgos destacan en mis ventas?». Para muchas empresas este diagnóstico ya es el primer informe serio sobre sus propios datos.

Evaluar

Con SQL y estadística, el equipo mide desempeño y relaciones: ventas por sucursal o vendedor, tasa de mora por tipo de cliente, correlación entre descuentos y volumen. Sobre una serie de precios, ingresos o caja calcula retorno total y medio, volatilidad (también anualizada), CAGR, ratio de Sharpe, máxima caída (drawdown) y VaR histórico al 95%, que permiten hablar de riesgo con números.

Anticipar

El científico de ML entrena modelos sobre los datos de la empresa y los compara entre sí. Siempre reporta la **línea base** (por ejemplo, predecir siempre la clase mayoritaria), para que quede claro si el modelo aporta algo o no, y grafica qué variables pesan más. Antes de entrenar, revisa si alguna variable «filtra» la respuesta. Un modelo entrenado se puede usar después para casos concretos: «¿qué riesgo tiene un solicitante de 22 años con empleo informal?».

Decidir

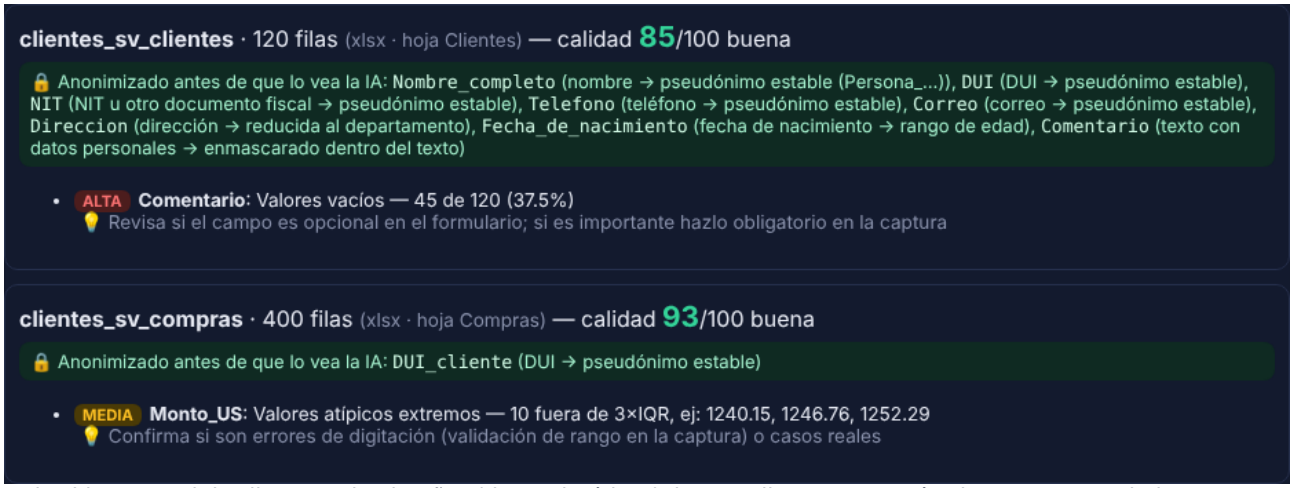
Dos herramientas responden las preguntas de todos los lunes. **¿Qué se va a agotar?**: con la demanda reciente, su tendencia y los días de entrega de cada proveedor, calcula la fecha de quiebre de cada producto, el stock de seguridad, el punto de reorden y cuánto pedir. **¿Qué ventas priorizar?**: aprende de las oportunidades ya ganadas y perdidas qué tan probable es cerrar cada una de las abiertas y las ordena por ganancia esperada (probabilidad × monto × margen). El modelo de lenguaje no hace estas cuentas: elige la herramienta y explica el resultado, y cada cifra queda en una tabla que se puede verificar con SQL.

Ejemplos de misiones por tipo de empresa

Empresa	Misión en lenguaje natural
Distribuidora o comercio	«Este es el Excel de ventas del ERP: revisa su calidad, límpialo y dime qué zona vende más.»
Cooperativa o financiera	«Predice qué créditos caerán en impago con Random Forest y compáralo con una regresión logística.»
Supermercado o ferretería	«¿Qué productos se van a agotar antes de que llegue el proveedor y cuánto debo pedir?»
Equipo comercial B2B	«¿Qué oportunidades de venta debo priorizar esta semana?»
Empresa de servicios	«Explora la base de datos y dime qué clientes concentran el 80% de la facturación.»
Área de sistemas	«Propón el esquema SQL para dejar de usar estos tres Excel y dime cómo capturar mejor los datos.»

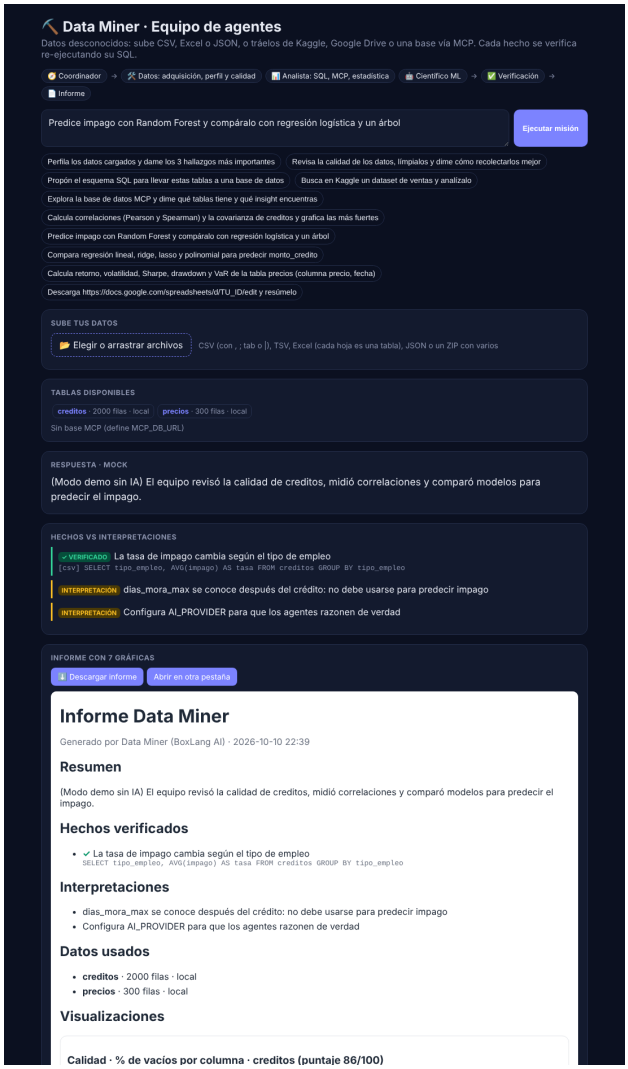
5. Por qué una empresa puede confiar en él

Preocupación	Cómo la resuelve Data Miner
«Mis datos tienen información de clientes.»	**Es lo primero que se resuelve.** Todo archivo se anonimiza al entrar, antes de que exista como tabla: DUI, NIT, nombres, teléfonos, correos y tarjetas pasan a pseudónimos estables (por ejemplo DUI_1a2b3c4d), las direcciones se reducen al departamento y la fecha de nacimiento a un rango de edad. Como el pseudónimo es estable, los cruces entre tablas siguen funcionando. La tabla para volver al dato real se queda en el servidor de la empresa y la IA no tiene forma de leerla.
«¿Y si la IA se inventa una cifra?»	Cada hecho lleva su consulta SQL y se vuelve a ejecutar antes de mostrarlo. El resultado sale ✓ o ✗. Las opiniones van aparte, etiquetadas como interpretaciones.
«No quiero que toque mi base de datos.»	El acceso a la base pasa por MCP con solo tres herramientas de lectura: listar tablas, describir una tabla y consultar con SELECT. Las herramientas de escritura del servidor nunca llegan al agente, y cualquier consulta que no sea SELECT se bloquea.
«Mis datos están desordenados.»	Se cargan tal como están (Excel con títulos, CSV con punto y coma, JSON). El diagnóstico de calidad dice qué falla y la limpieza trabaja sobre una copia: los datos originales no se modifican.
«¿El modelo realmente sirve?»	Se compara contra una línea base y se reportan métricas estándar: R^2, RMSE y MAE en regresión; accuracy, F1 y AUC en clasificación. Además se revisa la fuga de datos.
«¿Puedo revisar qué hizo?»	La interfaz muestra la traza completa: qué agente actuó y cada perfilado, diagnóstico, consulta y entrenamiento, en orden.
«Necesito compartirlo con la gerencia.»	El informe HTML se descarga, abre sin conexión y se imprime a PDF.
«No quiero depender de un solo proveedor de IA.»	Con BoxLang AI cada agente puede usar un proveedor distinto (Gemini, OpenAI y otros), configurable por agente.
«¿Cuánto cuesta?»	Todo el software es gratuito y de código abierto. El único límite es la cuota del proveedor de IA: con el equipo compacto y reintentos automáticos funciona dentro de un plan gratuito, y sin IA queda un modo demo.



Al subir un Excel de clientes salvadoreños (datos sintéticos), la pantalla muestra qué columnas se anonimizaron y cómo, junto al diagnóstico de calidad.

Cómo se ve



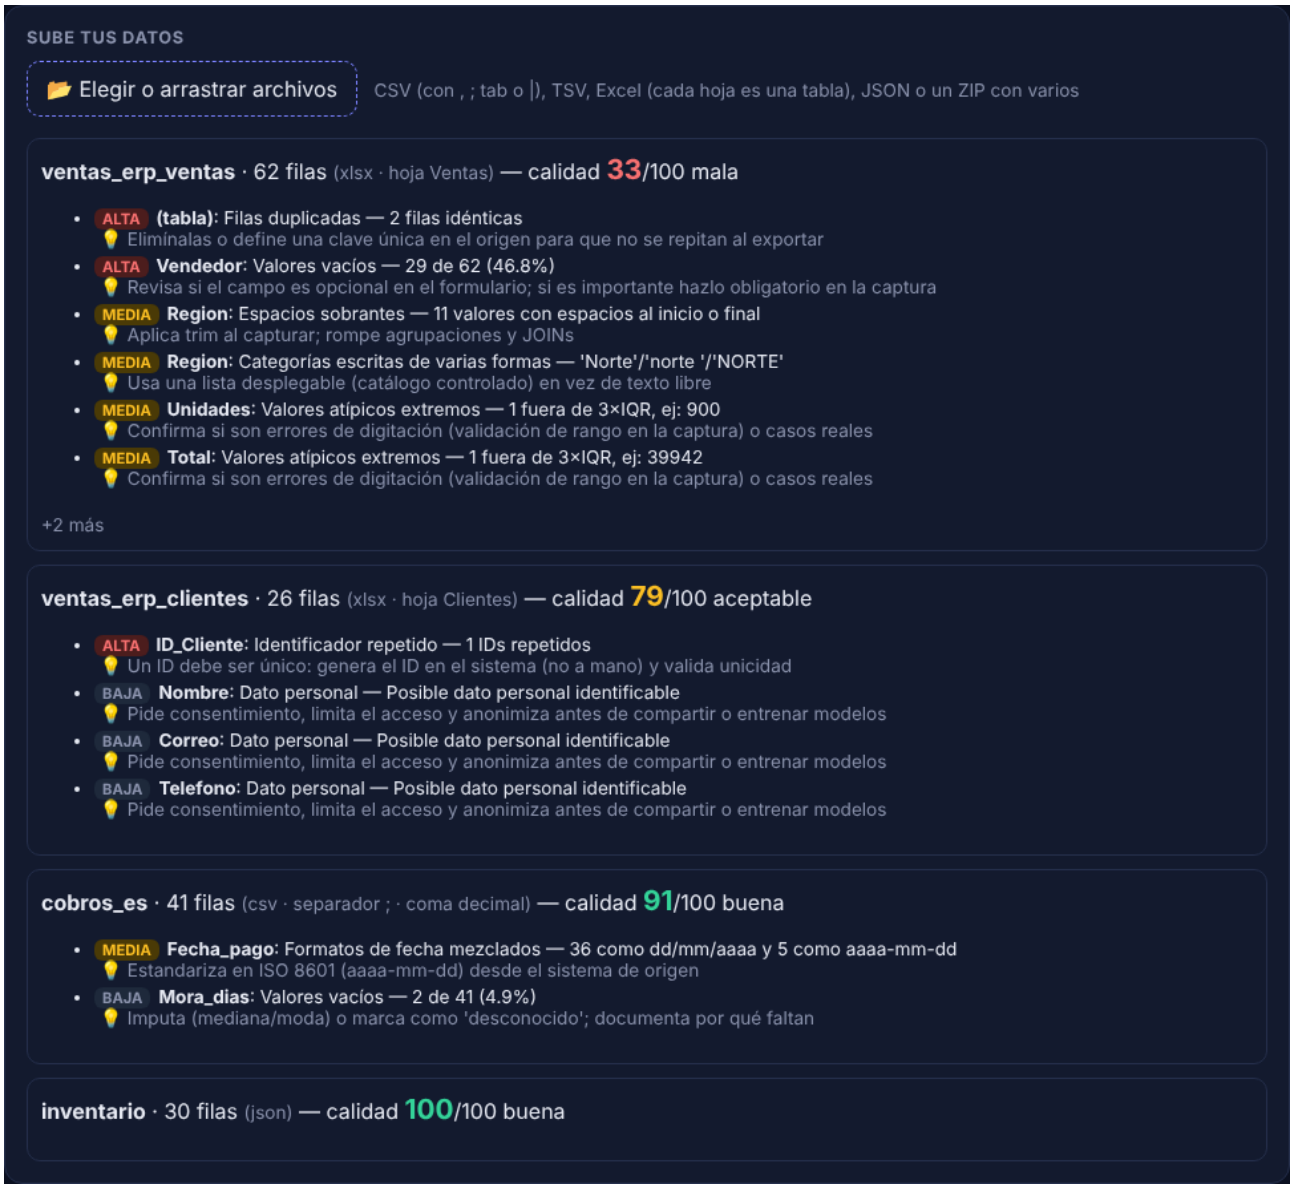
Misión de ML. «Predice impago con Random Forest y compáralo con regresión logística y un árbol».

Arriba están el equipo (coordinador, Datos, Analista y Científico ML) y las misiones sugeridas. En el centro aparecen los hechos y las interpretaciones, con la consulta SQL de cada hecho verificado. Abajo está el informe con la matriz de correlación.

Esta ejecución usa el modo demo, sin un modelo de lenguaje real, así que el texto de la respuesta es fijo. Las consultas, la estadística y los modelos sí se ejecutaron sobre los datos.

Cómo se ve: subir archivos y diagnóstico de calidad

Se subieron tres archivos de prueba «sucios»: un Excel de ERP con título, dos hojas, fórmulas y duplicados; un CSV con punto y coma y coma decimal; y un JSON anidado. Cada hoja y cada archivo se convierte en una tabla con su puntaje y sus problemas, antes de hacer cualquier pregunta.



Los archivos son de prueba, preparados para mostrar los problemas típicos; no son datos de una empresa real.

6. Lo que ya funciona

El prototipo se construyó con BoxLang 1.18, bx-ai 3.6, Tribuo 4.3.2 y Apache POI 5.2.5. Los resultados se obtuvieron con datasets sintéticos de ejemplo: 2.000 solicitudes de crédito, 300 días de precios y archivos de prueba con errores típicos. Sirven para mostrar que las piezas funcionan, no como resultados de una empresa real.

Pieza	Resultado
Flujo multiagente	Coordinador y tres subagentes con delegación, verificación e informe, probados de punta a punta en modo demo: 19 llamadas al modelo por misión completa (30 con el modo de siete especialistas). La respuesta final pasa por salida estructurada (structured output).
Anonimización	Excel de 120 clientes con DUI, NIT, teléfonos, correos y direcciones: 8 columnas anonimizadas y la hoja de compras unida por DUI anonimizado da los mismos totales que con los datos reales.
Formatos	Excel con varias hojas, título y fórmulas; CSV con punto y coma y coma decimal; TSV; JSON anidado; ZIP mixto. Todos cargados como tablas.
Calidad de datos	El Excel de prueba sale con calidad 33/100; tras la limpieza automática, 62/100. Detecta que «dias_mora_max» filtra la respuesta de «impago».
Estadística y finanzas	Pearson 0,7245, Spearman 0,656, covarianza −0,1377, Sharpe 0,805 y máxima caída −8,31%, coincidentes con Python.
Machine learning (créditos)	Monto: R^2 de 0,62 (lineal), 0,63 (polinomial) y 0,54 (Random Forest). Impago: accuracy 0,71 frente a 0,675 de la línea base.
Quiebre de stock	20 productos con 120 días de ventas: 1 agotado, 2 que se agotan antes de que llegue el proveedor y 5 en la semana siguiente, cada uno con cuánto pedir.
Prioridad de ventas	240 oportunidades cerradas para aprender y 80 abiertas para ordenar: accuracy 0,75 frente a 0,625 de la línea base; las variables que más pesan coinciden con cómo se generaron los datos.
Base de datos vía MCP	Probado con el servidor oficial de SQLite: lista, describe, consulta y bloquea lo que no es SELECT.
Informe y web	Interfaz, subida de archivos y API funcionando; informe HTML con gráficas embebidas.

> **Pendiente de validar antes de la demo:** el comportamiento con un modelo de lenguaje real (con API key), incluida la salida estructurada con ese proveedor, y la descarga real desde Google Drive y Kaggle (probadas contra enlaces convertidos y un servidor que imita la API).

Por qué BoxLang

- BoxLang AI trae agentes, **subagentes**, memoria y MCP como piezas del lenguaje, así que el equipo multiagente se arma en pocas líneas.
- Corre en la JVM, lo que permite usar Tribuo de Oracle para machine learning y Apache POI para Excel sin salir del proyecto ni montar un servicio aparte en Python.
- Usa las cinco piezas que propone el reto: agentes, herramientas, **salida estructurada**, **pipelines** y memoria.
- Las herramientas seguras (anonimización, SQL de solo lectura, calidad, conector MCP) se publican como el módulo **bx-datatools**, para que cualquier agente de BoxLang AI las use.

7. De prototipo a producto

Para que una empresa mediana lo use en el día a día, estos son los siguientes pasos naturales:

- **Conectores directos** a las bases más comunes (PostgreSQL, MySQL, SQL Server) mediante sus servidores MCP, manteniendo el acceso de solo lectura.
- **Drive privado** con un servidor MCP de Google Drive con OAuth, para leer las hojas internas sin hacerlas públicas.
- **Misiones programadas**: un informe semanal de ventas, mora o caja que llega solo, con los hechos ya verificados y el puntaje de calidad de los datos.
- **Seguimiento de calidad**: comparar el puntaje de cada fuente mes a mes para ver si las mejoras en la captura están funcionando.
- **Glosario del negocio**: que la empresa le explique al equipo qué significa cada tabla y cada indicador, para que las respuestas usen su propio vocabulario.
- **Alertas** cuando una métrica se sale de su rango habitual.

> **En resumen:** Data Miner le da a una empresa mediana lo que hace un pequeño departamento de datos: ordenar lo que tiene, entender qué dice, medir cómo va y anticipar lo que viene, con respuestas que se pueden comprobar y sin poner en riesgo su base de datos.